● 模型推演结果及比较:

```
2.90042013e-02 -1.17272303e-01 0.01090792e-02 -2.14636310e-02
-1.93212390e-01 -1.70112640e-01]
[-1.60855129e-02 -2.03645632e-01 4.16578650e-02 4.22625616e-02
3.01629305e-03 -1.39177904e-01 2.47835740e-02 -4.64780703e-02
-1.98652163e-01 4.78569046e-03]]
Time consuming: 0.08834 sec
```



```
C:\Users\taot\.conda\envs\pytorch2\python.exe D:\python\Pycharm\torch\predict.py
cuda:0
00011 1.0
0.1387750999999998
```



处理器	推演时长
TUP	0.08834s
CPU	0.1398s
GPU	0.1387s

同样的模型,分别使用CUP, TUP, GPU进行推理, TUP在张量计算时的效率远远高于CUP和GUP,充分展现TPU承载机器学习是实现人工智能的强有力方法。明显的体现了TPU的AI加速特性。

• 关键表 术介绍

```
# net = AlexNet(num_classes=17, init_weights=True)
net = models.vgg16(pretrained=True)
del net.classifier[2]
del net.classifier[4]
# print(net)
# num_features = net.fc.in_features
net.classifier[4] = nn.Linear(4096, 17)
print(net)
net.to(device)
#损失函数:这里用交叉熵
loss_function = nn.CrossEntropyLoss()
```

集成一套工具链,将vgg模型移植至少林派 (BM1684),并正确推演。

```
print(device)
del vgg.classifier[2]
del vgg.classifier[4]
vgg.classifier[4] = nn.Linear(4096, 17)
model =vgg
print(vgg)
model.load_state_dict(torch.load('Vgg_16.pth', map_location=device))
model = model.to(device)
example_input = torch.randn(1, 3, 32, 32).to(device)
traced_model = torch.jit.trace(model, example_input)
traced model.save('vgg 16.pt')
print("Model traced and saved successfully.")
model = torch.jit.load('vgg_16.pt', map_location="cpu")
model.eval()
input_data = torch.randn(1, 3, 32, 32)
traced_model = torch.jit.trace(model, [input_data])
traced model name = "vgg 16.pt"
traced_model.save('vgg_16.pt')
```

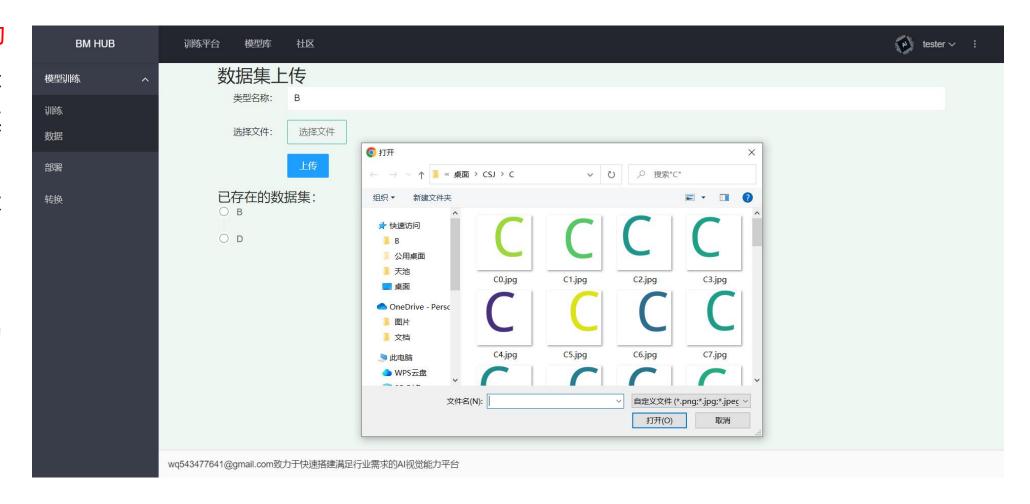
```
import cv2
import time
import argparse
import numpy as np
from PIL import Image
import sophon.sail as sail

def preprocess(img):
   image = Image.fromarray(img)
   resized_img = np.array(image.resize((224,224), resample=2))
   out = np.array(resized_img / 255., dtype=np.float32)
   return out.transpose((2, 0, 1))
```

• 类线理性支标外 容 绍

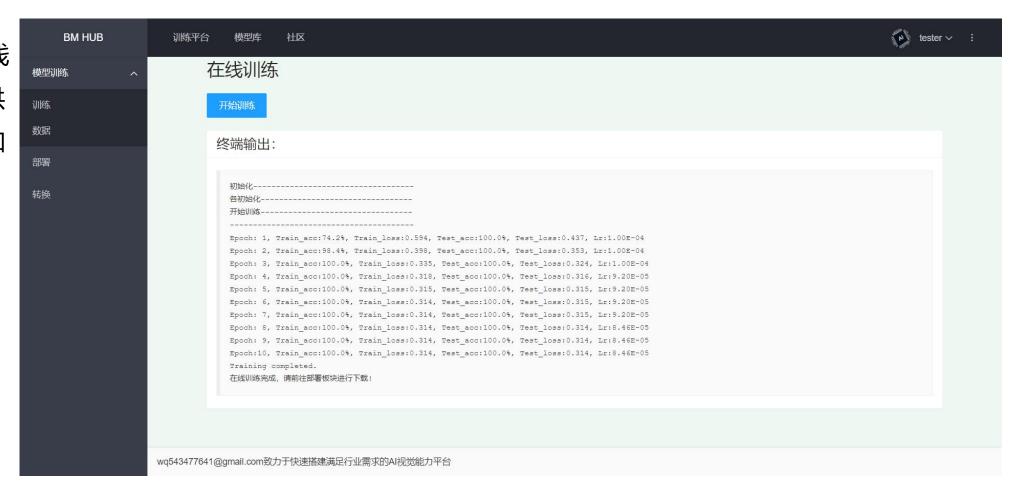
数据集上传功

能。用户可以轻 松地自行上传其 所需的数据集, 并设置数据的不 同类别和属性。 这为个性化的训 练提供了便捷的 手段。



• 类线弹性支性外外。

此外,我们的在线 训练功能为用户提供 了强大的在线训练和 转换服务。



●类线弹性支线外容

在训练完成后,

我们的工具链会 自动为用户生成 bmodel文件和 一份推演代码。 这些代码可以直 接供用户使用, 或封装为接口函 数,以支持用户 发新的AI应用。

